



# ANALISIS SENTIMEN PADA ULASAN APLIKASI TRANSPORTASI ONLINE MENGGUNAKAN MODEL TRANSFORMER INDOBERT DENGAN PENDEKATAN *EXPLAINABLE SENTIMENT ANALYSIS*

MIRANITA ANISA ROHMAH 11220940000055

Dosen Pembimbing 1 :

**Dhea Urfina Zulkifli, S.Mat., M.Si.**

Dosen Pembimbing 2 :

**Taufik Edy Sutanto, M.Sc.Tech., Ph.D.**

Dosen Penguji 1 :

**Dr. Nina Fitriyati, S.Si., M.Kom.**

Dosen Penguji 2 :

**Anggun Praptaningsih, S.Pd., M.Mat.**



# REVISI BU NINA

## Tambahan Eksperimen Konfigurasi Hyperparameter

| Exp | Batch Size | Learning Rate | Epoch | Weighted-F1 | Macro -F1 |
|-----|------------|---------------|-------|-------------|-----------|
| 1   | 8          | 1e-5          | 3     | 0.8853      | 0.6173    |
| 11  | 8          | 1e-5          | 4     | 0.8999      | 0.65282   |
| 2   | 8          | 2e-5          | 3     | 0.9050      | 0.6778    |
| 3   | 8          | 2e-5          | 4     | 0.9002      | 0.6712    |
| 4   | 8          | 3e-5          | 3     | 0.9030      | 0.6623    |
| 5   | 8          | 3e-5          | 4     | 0.8918      | 0.6492    |
| 6   | 16         | 2e-5          | 3     | 0.8973      | 0.6591    |
| 7   | 16         | 2e-5          | 4     | 0.8968      | 0.6551    |
| 8   | 16         | 3e-5          | 3     | 0.8933      | 0.6543    |
| 9   | 16         | 3e-5          | 4     | 0.8938      | 0.6591    |
| 10  | 32         | 2e-5          | 3     | 0.8909      | 0.6626    |
| 12  | 32         | 2e-5          | 4     | 0.89717     | 0.65466   |

## Eksperimen Tambahan

| Exp | Batch Size | Learning Rate | Epoch | Weighted-F1 | Macro -F1 |
|-----|------------|---------------|-------|-------------|-----------|
| 11  | 8          | 1e-5          | 4     | 0.8999      | 0.65262   |
| 12  | 32         | 2e-5          | 4     | 0.89717     | 0.65466   |

Meskipun telah dilakukan dua eksperimen tambahan, yaitu eksperimen 11 dan 12, model IndoBERT pada eksperimen ke-2 tetap menjadi yang terbaik berdasarkan nilai Weighted-F1, oleh karena itu model IndoBERT terbaik tetap model pada eksperimen ke-2.

# REVISI BU NINA

Apakah class weightingnya memiliki pengaruh?

Konfigurasi Hyperparameter Tuning Tanpa Penerapan Class Weighting

| <i>Exp</i> | <i>Batch Size</i> | <i>Learning Rate</i> | <i>Epoch</i> | <i>Weighted-F1</i> | <i>Macro-F1</i> |
|------------|-------------------|----------------------|--------------|--------------------|-----------------|
| 1          | 8                 | 1e-5                 | 3            | 0.9014             | 0.6573          |
| 11         | 8                 | 1e-5                 | 4            | 0.8991             | 0.6548          |
| 2          | 8                 | 2e-5                 | 3            | 0.9004             | 0.6582          |
| 3          | 8                 | 2e-5                 | 4            | 0.8927             | 0.6362          |
| 4          | 8                 | 3e-5                 | 3            | 0.8986             | 0.6337          |
| 5          | 8                 | 3e-5                 | 4            | 0.8951             | 0.6536          |
| 6          | 16                | 2e-5                 | 3            | 0.8950             | 0.6347          |
| 7          | 16                | 2e-5                 | 4            | 0.8886             | 0.6255          |
| 8          | 16                | 3e-5                 | 3            | 0.8945             | 0.6401          |
| 9          | 16                | 3e-5                 | 4            | 0.8957             | 0.6415          |
| 10         | 32                | 2e-5                 | 3            | 0.9044             | 0.6495          |
| 12         | 32                | 2e-5                 | 4            | 0.8953             | 0.6355          |



# REVISI BU NINA

Apakah class weightingnya memiliki pengaruh?

| Tanpa Class Weighting  |                  |               |                 |                |
|------------------------|------------------|---------------|-----------------|----------------|
| Kelas                  | <i>Precision</i> | <i>Recall</i> | <i>F1-Score</i> | <i>Support</i> |
| Negatif                | 8.505            | 9.282         | 8.877           | 613            |
| Netral                 | 2.174            | 1.667         | 1.020           | 75             |
| Positif                | 9.604            | 9.574         | 9.589           | 1292           |
|                        |                  |               |                 |                |
| Dengan Class Weighting |                  |               |                 |                |
| Kelas                  | <i>Precision</i> | <i>Recall</i> | <i>F1-Score</i> | <i>Support</i> |
| Negatif                | 8.420            | 9.217         | 8.801           | 613            |
| Netral                 | 2.500            | 1.600         | 1.951           | 75             |
| Positif                | 9.699            | 9.466         | 9.581           | 1292           |



# REVISI BU NINA

## Penulisan Rumus dan Perhitungan Class Weighting pada Draft Skripsi

### 3.5 Penanganan Ketidakseimbangan Kelas dengan *Class Weighting*

Secara matematis, bobot untuk setiap kelas dihitung menggunakan metode *balanced class weight* dengan rumus sebagai berikut [35]:

$$w_i = \frac{N}{K \times n_i} \quad (3.1)$$

dengan:

$w_i$  : bobot untuk kelas ke- $i$ ,

$N$  : total seluruh sampel dalam data pelatihan,

$K$  : jumlah kelas,

$n_i$  : jumlah sampel pada kelas  $i$ .

Berdasarkan Persamaan (3.1), bobot setiap kelas berbanding terbalik dengan jumlah sampel pada kelas tersebut. Semakin sedikit jumlah data pada suatu kelas, semakin besar bobot yang diberikan sehingga kesalahan klasifikasi pada kelas tersebut akan memberikan kontribusi *loss* yang lebih besar selama proses pelatihan. Sebaliknya, kelas dengan jumlah sampel yang lebih banyak memperoleh bobot yang lebih kecil karena telah memiliki representasi yang memadai dalam data pelatihan.

Contoh perhitungan `class_weight` berdasarkan data pada penelitian ini:

| Keterangan           | Jumlah |
|----------------------|--------|
| Total Data Latih (N) | 15.835 |
| Kelas Sentimen (K)   | 3      |
| $n_{negatif}$        | 4.897  |
| $n_{netral}$         | 606    |
| $n_{positif}$        | 10.332 |

Maka:

$$w_{negatif} = \frac{15.835}{3 \times 4.897} = 1,0779$$

$$w_{netral} = \frac{15.835}{3 \times 606} = 8,710$$

$$w_{positif} = \frac{15.835}{3 \times 10.332} = 0,511$$

Bobot kelas netral yang jauh lebih besar (8,710) dibandingkan kelas positif (0,511) dan kelas negatif (1,0779) menunjukkan bahwa model akan memberikan penalti yang jauh lebih tinggi jika salah mengklasifikasikan ulasan dengan sentimen netral.

# REVISI BU NINA

## Rumus dan Perhitungan Class Weighting

Hasil Class Weighting pada Python

|   | label | weight   |
|---|-------|----------|
| 0 | 0     | 1.077871 |
| 1 | 1     | 8.710121 |
| 2 | 2     | 0.510872 |

Rumus Class Weight:

$$w_i = \frac{N}{K \times n_i}$$

menghitung bobot untuk setiap kelas sentimen:

$$w_{negatif} = \frac{15.835}{3 \times 4.897} = 1,0779$$

$$w_{netral} = \frac{15.835}{3 \times 606} = 8,710$$

$$w_{positif} = \frac{15.835}{3 \times 10.332} = 0,511$$

| Keterangan           | Jumlah |
|----------------------|--------|
| Total Data Latih (N) | 15.835 |
| Kelas Sentimen (K)   | 3      |
| $n_{negatif}$        | 4.897  |
| $n_{netral}$         | 606    |
| $n_{positif}$        | 10.332 |

# REVISI BU NINA

## Rumus dan Perhitungan Class Weighting

teks ulasan: "makin lama makin lemot setiap ada kasus tidak berpihak pada customer buat laporan tidak jelas penyelesaiannya"

| Label  |          | Probabilitas Prediksi Model |          |          | Confidence |
|--------|----------|-----------------------------|----------|----------|------------|
| Aktual | Prediksi | Negatif                     | Netral   | Positif  |            |
| Netral | Negatif  | 0,977499                    | 0,015373 | 0,007128 | 0.99817    |

one-hot encoding  $y = [y_{negatif}, y_{netral}, y_{positif}] = [0, 1, 0]$

nilai loss:

$$L_i = -C_w^i \times y_i \times \log(p_i)$$

total loss:

$$L_{total} = \sum_{i=0}^2 L_i$$

$N$  : total seluruh sampel dalam data pelatihan,  
 $K$  : jumlah kelas sentimen,  
 $n_i$  : jumlah sampel pada kelas  $i$ .  
 $w_i$  : bobot kelas ke- $i$ , hasil perhitungan *class weighting*,  
 $y_i$  : label asli (*one-hot encoding*),  
 $p_i$  : probabilitas prediksi model IndoBERT,  
 $L_i$  : *loss* per kelas,  
 $L_{total}$  : total *loss*.



# REVISI BU NINA

## Rumus dan Perhitungan Class Weighting

$$L_i = -C_w^i \times y_i \times \log(p_i)$$

"makin lama makin lemot setiap ada kasus tidak berpihak pada customer buat laporan tidak jelas penyelesaiannya"

Perhitungan tanpa Class weighting ( $w_i=1$  untuk semua kelas)

$$\begin{aligned} L_{negatif} &= -w_i \times y_i \times \log(p_i) \\ &= -1 \times 0 \times \log(0,977499) \\ &= -1 \times 0 \times (-0,022758) \\ &= 0 \end{aligned}$$

$$\begin{aligned} L_{netral} &= -w_i \times y_i \times \log(p_i) \\ &= -1 \times 1 \times \log(0,015373) \\ &= -1 \times 1 \times (-4,175139) \\ &= 4,175139 \end{aligned}$$

$$\begin{aligned} L_{positif} &= -w_i \times y_i \times \log(p_i) \\ &= -1 \times 0 \times \log(0,007128) \\ &= -1 \times 0 \times (-4,943672) \\ &= 0 \end{aligned}$$

$$\begin{aligned} L_{total} &= L_{negatif} + L_{netral} + L_{positif} \\ &= 0 + 4,175139 + 0 \\ &= 4,175139 \end{aligned}$$

Perhitungan dengan Class Weighting

$$\begin{aligned} L_{negatif} &= -w_i \times y_i \times \log(p_i) \\ &= -1,0779 \times 0 \times \log(0,977499) \\ &= -1,0779 \times 0 \times (-0,022758) \\ &= 0 \end{aligned}$$

$$\begin{aligned} L_{netral} &= -w_i \times y_i \times \log(p_i) \\ &= -8,7101 \times 0 \times \log(0,015373) \\ &= -8,7101 \times 0 \times (-4,175139) \\ &= 36,365878 \end{aligned}$$

$$\begin{aligned} L_{positif} &= -w_i \times y_i \times \log(p_i) \\ &= -0,5109 \times 1 \times \log(0,007128) \\ &= -0,5109 \times (-4,943672) \\ &= 0,000937 \end{aligned}$$

$$\begin{aligned} L_{total} &= L_{negatif} + L_{netral} + L_{positif} \\ &= 0 + 36,365878 + 0 \\ &= 36,365878 \end{aligned}$$

$$\frac{L_{weighted}}{L_{plain}} = \frac{-w_i \times 1 \times \log(p_i)}{-1 \times 1 \times \log(p_i)} = w_i$$

$$\frac{L_{dengan\ weighting}}{L_{tanpa\ weighting}} = \frac{36,365878}{4,175139} = 8,7101$$

Hasilnya sesuai dengan bobot pada kelas netral.

| Perbandingan Penerapan <i>Class Weighting</i> | Nilai Loss       |
|-----------------------------------------------|------------------|
| <b>Tanpa Class Weighting</b>                  | <b>4,175139</b>  |
| <b>Dengan Class Weighting</b>                 | <b>36,365878</b> |

# REVISI BU NINA

## Penulisan Rumus Matriks Evaluasi *Micro-F1*, *Macro-F1*, dan *Weihted-F1*

Sebelum

|                          |                                                                             |                                                                                                                                                                                                                   |
|--------------------------|-----------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <i>F1-Score</i>          | $2 \times \frac{(Precision_i \times Recall_i)^i}{(Precision_i + Recall_i)}$ | Mengukur keseimbangan antara <i>precision</i> dan <i>recall</i> sehingga dapat memberikan evaluasi yang lebih representatif terhadap performa model (terutama pada kondisi distribusi data yang tidak seimbang).  |
| <i>Macro F1-Score</i>    | $\frac{1}{K} \sum_{i=1}^K F1_i$                                             | Rata-rata aritmetik <i>F1-Score</i> dari seluruh kelas tanpa mempertimbangkan proporsi data. Memberikan bobot yang sama pada setiap kelas, sehingga sensitif terhadap performa kelas minoritas.                   |
| <i>Weighted F1-Score</i> | $\sum_{i=1}^K \frac{n_i}{N} F1_i$                                           | Rata-rata tertimbang <i>F1-Score</i> dengan bobot berdasarkan proporsi jumlah data pada setiap kelas, sehingga kelas dengan jumlah data lebih banyak memberikan kontribusi yang lebih besar terhadap nilai akhir. |

dengan  $i \in \{0,1,2\}$  di mana 0, 1, dan 2 masing-masing merepresentasikan kelas negatif, netral, dan positif. Indeks  $i$  menyatakan kelas yang sedang dievaluasi, sedangkan  $j$  menyatakan indeks seluruh kelas yang digunakan dalam operasi penjumlahan untuk memperoleh total jumlah data aktual dari semua kelas. Adapun notasi yang digunakan adalah sebagai berikut.

- $TP_i$  : jumlah data pada kelas  $i$  yang diprediksi dengan benar (**True Positive**),
- $FP_i$  : jumlah data yang diprediksi sebagai kelas  $i$ , tetapi sebenarnya berasal dari kelas lain (**False Positive**),
- $FN_i$  : jumlah data pada kelas  $i$  yang diprediksi sebagai kelas lain (**False Negative**),
- $F1_i$  : nilai *F1-Score* pada kelas  $i$ ,
- $n_t$  : jumlah data pada kelas ke- $i$ ,
- $N$  : jumlah seluruh data,
- $K$  : jumlah kelas sentimen.


Sesudua

|                          |                                                                                                                                                                                                                                                                                           |                                                                                                                                                                                                                                                                                                                                                                                            |
|--------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <i>Micro F1-Score</i>    | $\frac{2 \times Precision_{micro} \times Recall_{micro}}{Precision_{micro} + Recall_{micro}}$<br><br>dengan,<br><br>$Precision_{micro} = \frac{\sum_{i=0}^2 TP_i}{\sum_{i=0}^2 (TP_i + FP_i)}$<br><br>$Recall_{micro} = \frac{\sum_{i=0}^2 TP_i}{\sum_{i=0}^2 (TP_i + FN_i)}$<br><br>[36] | <i>Micro F1-Score</i> merupakan nilai <i>F1-Score</i> yang dihitung berdasarkan akumulasi seluruh TP, FP, dan FN dari semua kelas terlebih dahulu, kemudian digunakan untuk menghitung nilai <i>precision</i> dan <i>recall</i> . Dengan demikian, setiap data uji memiliki kontribusi yang sama terhadap nilai akhir tanpa memperhatikan distribusi jumlah data pada masing-masing kelas. |
| <i>Macro F1-Score</i>    | $\frac{1}{3} \sum_{i=0}^2 F1_i$ [36]                                                                                                                                                                                                                                                      | Rata-rata aritmetik <i>F1-Score</i> dari seluruh kelas tanpa mempertimbangkan proporsi data. Memberikan bobot yang sama pada setiap kelas, sehingga sensitif terhadap performa kelas minoritas.                                                                                                                                                                                            |
| <i>Weighted F1-Score</i> | $\sum_{i=0}^2 w_i F1_i$ , dengan<br><br>$w_i = \frac{TP_i + FN_i}{\sum_{j=0}^2 TP_j + FN_j}$ [36]                                                                                                                                                                                         | Rata-rata tertimbang <i>F1-Score</i> dengan bobot berdasarkan proporsi jumlah data pada setiap kelas, sehingga kelas dengan jumlah data lebih banyak memberikan kontribusi yang lebih besar terhadap nilai akhir.                                                                                                                                                                          |

# REVISI BU NINA

## Perhitungan Matriks Evaluasi

### Confusion Matrix:



- True Positive (TP)* : jumlah data yang berhasil diprediksi dengan benar sebagai anggota kelas yang sedang dievaluasi, yaitu nilai yang berada pada elemen diagonal *confusion matrix*.
- False Positive (FP)* : jumlah data yang sebenarnya berasal dari kelas lain, tetapi diprediksi sebagai kelas yang sedang dievaluasi, yaitu jumlah nilai pada kolom kelas tersebut di luar elemen diagonal.
- False Negative (FN)* : jumlah data yang sebenarnya termasuk dalam kelas yang sedang dievaluasi, tetapi diprediksi sebagai kelas lain, yaitu jumlah nilai pada baris kelas tersebut di luar elemen diagonal.
- True Negative (TN)* : jumlah data yang bukan berasal dari kelas yang sedang dievaluasi dan juga tidak diprediksi sebagai kelas tersebut, yaitu seluruh nilai yang berada di luar baris dan kolom kelas yang sedang dievaluasi.

| Kelas   | TP   | FP                | FN               | TN                              |
|---------|------|-------------------|------------------|---------------------------------|
| Negatif | 565  | $(51 + 55) = 106$ | $(22 + 26) = 48$ | $(12 + 12 + 14 + 1223) = 1261$  |
| Netral  | 12   | $(22 + 14) = 36$  | $(51 + 12) = 63$ | $(565 + 26 + 55 + 1223) = 1869$ |
| Positif | 1223 | $(26 + 12) = 38$  | $(55 + 14) = 69$ | $(565 + 22 + 51 + 12) = 650$    |



# REVISI BU NINA

## Perhitungan Matriks Evaluasi

Matriks Precision, Recall, dan F1-Score untuk setiap kelas:

### Kelas Negatif

Dari confusion matrix, baris "Negatif" = [565, 22, 26], kolom "Negatif" = [565, 51, 55]:

$$TP = 565$$

$$FN = 22 + 26 = 48$$

$$FP = 51 + 55 = 106$$

$$Precision = \frac{TP}{TP + FP} = \frac{565}{565 + 106} = \frac{565}{671} = 0.8420$$

$$Recall = \frac{TP}{TP + FN} = \frac{565}{565 + 48} = \frac{565}{613} = 0.9217$$

$$F1 = \frac{2 \times P \times R}{P + R} = \frac{2 \times 0.8420 \times 0.9217}{0.8420 + 0.9217} = 0.8801$$

### Kelas Netral

Baris "Netral" = [51, 12, 12], kolom "Netral" = [22, 12, 14]:

$$TP = 12$$

$$FN = 51 + 12 = 63$$

$$FP = 22 + 14 = 36$$

$$Precision = \frac{TP}{TP + FP} = \frac{12}{12 + 36} = \frac{12}{48} = 0.2500$$

$$Recall = \frac{TP}{TP + FN} = \frac{12}{12 + 63} = \frac{12}{75} = 0.1600$$

$$F1 = \frac{2 \times P \times R}{P + R} = \frac{2 \times 0.2500 \times 0.1600}{0.2500 + 0.1600} = 0.1951$$

### Kelas Positif

Baris "Positif" = [55, 14, 1223], kolom "Positif" = [26, 12, 1223]:

$$TP = 1223$$

$$FN = 55 + 14 = 69$$

$$FP = 26 + 12 = 38$$

$$Precision = \frac{TP}{TP + FP} = \frac{1223}{1223 + 38} = \frac{1223}{1261} = 0.9699$$

$$Recall = \frac{TP}{TP + FN} = \frac{1223}{1223 + 69} = \frac{1223}{1292} = 0.9466$$

$$F1 = \frac{2 \times P \times R}{P + R} = \frac{2 \times 0.9699 \times 0.9466}{0.9699 + 0.9466} = 0.9581$$

| Kelas   | Precision | Recall | F1-Score | Support |
|---------|-----------|--------|----------|---------|
| Negatif | 0.8420    | 0.9217 | 0.8801   | 613     |
| Netral  | 0.2500    | 0.1600 | 0.1951   | 75      |
| Positif | 0.9699    | 0.9466 | 0.9581   | 1292    |

# REVISI BU NINA

## Perhitungan Matriks Evaluasi

### Micro Precision

$$\text{Micro Precision} = \frac{TP_0 + TP_1 + TP_2}{(TP_0 + TP_1 + TP_2) + (FP_0 + FP_1 + FP_2)}$$

Substitusi nilai:

$$\begin{aligned}\text{Micro Precision} &= \frac{565 + 12 + 1223}{(565 + 12 + 1223) + (106 + 36 + 38)} \\ &= \frac{1800}{1800 + 180} \\ &= \frac{1800}{1980} \\ &= 0,909\end{aligned}$$

### Micro Recall

$$\text{Micro Recall} = \frac{TP_0 + TP_1 + TP_2}{(TP_0 + TP_1 + TP_2) + (FN_0 + FN_1 + FN_2)}$$

Substitusi nilai:

$$\begin{aligned}\text{Micro Recall} &= \frac{565 + 12 + 1223}{(565 + 12 + 1223) + (48 + 63 + 69)} \\ &= \frac{1800}{1800 + 180} \\ &= \frac{1800}{1980} \\ &= 0,909\end{aligned}$$

### Micro-F1:

$$\begin{aligned}\text{Micro F1} &= \frac{2 \times (\text{Micro Precision} \times \text{Micro Recall})}{\text{Micro Precision} + \text{Micro Recall}} \\ &= \frac{2 \times (0,909 \times 0,909)}{0,909 + 0,909} \\ &= \frac{2 \times 0,826}{1,818} \\ &= \frac{1,652}{1,818} \\ &= 0,909\end{aligned}$$

### Macro F1:

$$\begin{aligned}\text{Macro F1} &= \frac{(F1_1 + F1_2 + F1_3)}{K} \\ &= \frac{0,8801 + 0,1951 + 0,9581}{3} \\ &= \frac{2,0333}{3} \\ &= 0,6778\end{aligned}$$

# REVISI BU NINA

## Perhitungan Matriks Evaluasi

Accuracy:

$$\begin{aligned}
 \text{Accuracy} &= \frac{TP_0 + TP_1 + TP_2}{N} \\
 &= \frac{565 + 12 + 1223}{1980} \\
 &= \frac{1800}{1980} \\
 &= 0.9091 = 90.91\%
 \end{aligned}$$

Hasil Matriks Evaluasi:

| Metrik Evaluasi   | Nilai           |
|-------------------|-----------------|
| Accuracy          | 0,9091 (90.91%) |
| Macro F1-Score    | 0,6778          |
| Micro F1-Score    | 0,9091          |
| Weighted F1-Score | 0,9050          |

Weighted F1:

### Weighted F1-Score

Weighted f1 score dihitung menggunakan rata-rata tertimbang dari nilai f1 score setiap kelas.

$$\text{Weighted F1} = w_0 F1_0 + w_1 F1_1 + w_2 F1_2$$

Sehingga untuk masing-masing kelas diperoleh:

$$w_i = \frac{TP_i + FN_i}{(TP_0 + FN_0) + (TP_1 + FN_1) + (TP_2 + FN_2)}$$

Sehingga untuk masing-masing kelas diperoleh

$$w_0 = \frac{565 + 48}{1980} = \frac{613}{1980}$$

$$w_1 = \frac{12 + 63}{1980} = \frac{75}{1980}$$

$$w_2 = \frac{1223 + 69}{1980} = \frac{1292}{1980}$$

Selanjutnya dilakukan substitusi ke dalam rumus Weighted F1.

$$\begin{aligned}
 \text{Weighted F1} &= \left( \frac{565 + 48}{1980} \times 0,880 \right) + \left( \frac{12 + 63}{1980} \times 0,195 \right) + \left( \frac{1223 + 69}{1980} \times 0,958 \right) \\
 &= \left( \frac{613}{1980} \times 0,880 \right) + \left( \frac{75}{1980} \times 0,195 \right) + \left( \frac{1292}{1980} \times 0,958 \right) \\
 &= \frac{(613 \times 0,880) + (75 \times 0,195) + (1292 \times 0,958)}{1980} \\
 &= \frac{539,440 + 14,625 + 1237,736}{1980} \\
 &= \frac{1791,801}{1980} \\
 &= 0,905
 \end{aligned}$$



# REVISI BU NINA

## Menambahkan Keterbatasan Penelitian

### 5.3 Keterbatasan Penelitian

Penelitian ini memiliki beberapa keterbatasan yang perlu diperhatikan dalam menginterpretasikan hasil penelitian. Dataset yang digunakan mengalami *extreme class imbalance*, di mana kelas netral hanya terdiri atas 757 data sehingga jumlahnya jauh lebih sedikit dibandingkan kelas negatif dan positif. Kondisi tersebut menyebabkan representasi karakteristik sentimen netral menjadi terbatas selama proses pelatihan model.

Untuk mengurangi dampak ketidakseimbangan kelas, penelitian ini menerapkan *class weighting* pada fungsi *loss* tanpa melakukan teknik penyeimbangan data (*resampling*), sehingga distribusi data asli tetap dipertahankan dan merepresentasikan kondisi data riil. Meskipun demikian, pendekatan tersebut belum sepenuhnya mampu mengatasi keterbatasan jumlah data pada kelas netral.

Keterbatasan tersebut berdampak pada kemampuan model dalam mengenali karakteristik sentimen netral, yang ditunjukkan oleh nilai *precision*, *recall*, dan *F1-score* yang lebih rendah dibandingkan kelas lainnya. Hasil *confusion matrix* juga menunjukkan bahwa sebagian besar data sentimen netral lebih sering diprediksi sebagai sentimen negatif daripada sebagai sentimen netral. Oleh karena itu, penelitian selanjutnya dapat mengeksplorasi teknik penanganan ketidakseimbangan data, seperti *oversampling*, *undersampling*, atau *data augmentation*, untuk meningkatkan representasi kelas minoritas sehingga performa klasifikasi, khususnya pada kelas netral, dapat ditingkatkan.



# REVISI BU NINA

## Perhitungan LIME

$$\xi(x) = \arg \min_{g \in \mathcal{G}} [L(f, g, \pi_x) + \Omega(g)]$$

dengan:

- $\xi(x)$  : penjelasan lokal (*local explanation*) yang dihasilkan *LIME* untuk sampel  $x$ ,
- $x$  : data atau teks yang akan dijelaskan prediksinya. Dalam penelitian ini berupa ulasan aplikasi Gojek,
- $\arg \min$  : operasi optimasi untuk mencari nilai yang menghasilkan fungsi objektif minimum,
- $g$  : model interpretasi sederhana (*surrogate model*) yang digunakan untuk mendekati perilaku model asli di sekitar sampel  $x$ . Biasanya berupa regresi linear,
- $G$  : kumpulan semua model interpretasi sederhana yang dapat dipilih oleh *LIME*,
- $f$  : model asli (*black-box model*) yang ingin dijelaskan, misalnya IndoBERT,
- $L(f, g, \pi_x)$  : fungsi *loss* yang mengukur seberapa baik model sederhana  $g$  mampu meniru prediksi model asli  $f$  di sekitar sampel  $x$ ,
- $\pi_x$  : ukuran kedekatan (*proximity measure*) yang memberikan bobot lebih besar pada sampel yang mirip dengan  $x$ ,
- $\Omega(g)$  : kompleksitas model interpretasi  $g$  (model *surrogate*). Digunakan agar model penjelasan tetap sederhana dan mudah dipahami.

### Korespondensi dengan perhitungan manual:

- $f \rightarrow$  model IndoBERT, menghasilkan  $f(z)$  = probabilitas kelas negatif (vektor  $y$ )
- $g \rightarrow$  model linear lokal,  $g(z) = \beta_0 + \beta_1 z_1 + \beta_2 z_2$
- $\pi_x \rightarrow$  kernel similarity,  $\pi_x(z) = \exp\left(-\frac{D(x, z)^2}{\sigma^2}\right)$ , direpresentasikan sebagai matriks diagonal  $W$
- $L(f, g, \pi_x) \rightarrow$  fungsi loss kuadrat berbobot:

$$L(f, g, \pi_x) = \sum_{z \in Z} \pi_x(z) (f(z) - g(z))^2$$

yang dalam bentuk matriks diselesaikan melalui solusi least squares tertimbang:

$$\beta = (X^T W X)^{-1} X^T W y$$

- $\Omega(g) \rightarrow$  berfungsi membatasi jumlah kata yang dijelaskan. Pada perhitungan ini jumlah kata sudah kami tentukan sendiri di awal yaitu 2 kata, sehingga  $\Omega(g)$  bernilai 0 karena tidak ada proses seleksi fitur tambahan yang diperlukan.

# REVISI BU NINA

## Perhitungan LIME

teks ulasan: aplikasi gak guna

### Data

Instance: “*aplikasi gak guna*”, token yang dijelaskan:  $x_i = \text{“gak”}$ , fitur:  $z_1 = \text{aplikasi}$ ,  $z_2 = \text{guna}$ ,  $m = 2$ .

### 1. Perturbasi

$$X = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \\ 1 & 1 & 1 \end{bmatrix}$$

Tabel Sampel Perturbasi LIME

| No | $z_1$ (aplikasi) | $z_2$ (guna) | Text S            |
|----|------------------|--------------|-------------------|
| 1  | 0                | 0            | gak               |
| 2  | 0                | 1            | guna gak          |
| 3  | 1                | 0            | aplikasi gak      |
| 4  | 1                | 1            | aplikasi guna gak |

Perlu diperhatikan bahwa token target “gak” selalu dipertahankan karena token tersebut merupakan token yang ingin dijelaskan kontribusinya.

### 2. Prediksi model $f(z)$

$$y = \begin{bmatrix} 0.95072705 \\ 0.95440847 \\ 0.99457490 \\ 0.99358517 \end{bmatrix}$$

### 3. Kernel similarity

$$\pi_x(z) = \exp\left(-\frac{D(x, z)^2}{\sigma^2}\right)$$

$$W = \begin{bmatrix} 0.727916 & 0 & 0 & 0 \\ 0 & 0.941893 & 0 & 0 \\ 0 & 0 & 0.941893 & 0 \\ 0 & 0 & 0 & 1.000000 \end{bmatrix}$$

### 4. Transpose $X^T$

$$X^T = \begin{bmatrix} 1 & 1 & 1 & 1 \\ 0 & 0 & 1 & 1 \\ 0 & 1 & 0 & 1 \end{bmatrix}$$



# REVISI BU NINA

## Perhitungan LIME

4. Transpose  $X^T$

$$X^T = \begin{bmatrix} 1 & 1 & 1 & 1 \\ 0 & 0 & 1 & 1 \\ 0 & 1 & 0 & 1 \end{bmatrix}$$

5.  $X^T W$

$$X^T W = \begin{bmatrix} 0.727916 & 0.941893 & 0.941893 & 1.000000 \\ 0 & 0 & 0.941893 & 1.000000 \\ 0 & 0.941893 & 0 & 1.000000 \end{bmatrix}$$

6.  $X^T W X$

$$X^T W X = \begin{bmatrix} 3.611701 & 1.941893 & 1.941893 \\ 1.941893 & 1.941893 & 1.000000 \\ 1.941893 & 1.000000 & 1.941893 \end{bmatrix}$$

7.  $(X^T W X)^{-1}$

$$(X^T W X)^{-1} = \begin{bmatrix} 0.954124 & -0.629801 & -0.629801 \\ -0.629801 & 1.116525 & 0.054833 \\ -0.629801 & 0.054833 & 1.116525 \end{bmatrix}$$

8.  $X^T W y$

$$X^T W y = \begin{bmatrix} 3.521368 \\ 1.930368 \\ 1.892535 \end{bmatrix}$$

9. Koefisien  $\beta = (X^T W X)^{-1} X^T W y$

$$\beta_0 = 0.954124(3.521368) - 0.629801(1.930368) - 0.629801(1.892535) = 0.952154$$

$$\beta_1 = -0.629801(3.521368) + 1.116525(1.930368) + 0.054833(1.892535) = 0.041318$$

$$\beta_2 = -0.629801(3.521368) + 0.054833(1.930368) + 1.116525(1.892535) = 0.001152$$

$$\beta = \begin{bmatrix} 0.952154 \\ 0.041318 \\ 0.001152 \end{bmatrix}$$

10. Model surrogate

$$g(z) = 0.952154 + 0.041318z_1 + 0.001152z_2$$

# REVISI BU NINA

## Perhitungan SHAP

$$\phi_i = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|!(|N| - |S| - 1)!}{|N|!} [f(S \cup \{i\}) - f(S)]$$

- $f(S)$  = logit model pada koalisi  $S$
- $f(S \cup \{i\}) - f(S)$  = marginal contribution
- Bobot = faktor pembobot Shapley

| Koalisi             | Logit_Negatif |
|---------------------|---------------|
| $\emptyset$         | 2.429775      |
| {aplikasi}          | 2.012054      |
| {gak}               | 4.113923      |
| {guna}              | -0.500337     |
| {aplikasi,gak}      | 4.159345      |
| {aplikasi,guna}     | -1.281649     |
| {gak,guna}          | 4.202475      |
| {aplikasi,gak,guna} | 4.206476      |

dengan:

- $\phi_i$  : nilai *sapley* untuk fitur ke- $i$ ,
- $|S|$  : kardinalitas (jumlah anggota) dari himpunan  $S$ ,
- $|N|$  : himpunan seluruh fitur,
- $f(S)$  : prediksi model menggunakan fitur pada subset  $S$ ,
- $f(S \cup \{i\})$  : prediksi model setelah fitur ke- $i$  ditambahkan ke dalam subset  $S$ ,
- $f_x(S)$  : fungsi nilai *SHAP* (*value function*),
- $E[\cdot]$  : ekspektasi (nilai rata-rata),
- $x$  : data atau sampel yang akan dijelaskan,
- $x_S$  : subset fitur yang diketahui.

# REVISI BU NINA

## Perhitungan SHAP

### Perhitungan Base Value (Expected Value)

Rumus

$$E[f(x)] = f(\emptyset)$$

Substitusi

$$\begin{aligned} E[f(x)] &= f([\text{MASK}] [\text{MASK}] [\text{MASK}]) \\ &= 2.429775 \end{aligned}$$

Hasil

$$\boxed{E[f(x)] = 2.429775}$$



# REVISI BU NINA

## Perhitungan SHAP

**Tabel Koalisi Token “aplikasi”**

Karena yang dihitung adalah token “aplikasi”, maka koalisi yang digunakan adalah semua koalisi yang tidak mengandung token “aplikasi”.

| No | Koalisi $S$            | $S \cup \{\text{aplikasi}\}$     | Bobot                              |
|----|------------------------|----------------------------------|------------------------------------|
| 1  | $\emptyset$            | $\{\text{aplikasi}\}$            | $\frac{0! (2)!}{3!} = \frac{1}{3}$ |
| 2  | $\{\text{gak}\}$       | $\{\text{aplikasi, gak}\}$       | $\frac{1! (1)!}{3!} = \frac{1}{6}$ |
| 3  | $\{\text{guna}\}$      | $\{\text{aplikasi, guna}\}$      | $\frac{1! (1)!}{3!} = \frac{1}{6}$ |
| 4  | $\{\text{gak, guna}\}$ | $\{\text{aplikasi, gak, guna}\}$ | $\frac{2! (0)!}{3!} = \frac{1}{3}$ |

### Perhitungan SHAP Token “aplikasi”

#### Koalisi 1

$$\begin{aligned} S &= \emptyset \\ \frac{|S|! (|N| - |S| - 1)!}{|N|!} &= \frac{0! (3 - 0 - 1)!}{3!} = \frac{2}{6} = \frac{1}{3} \\ \phi_1 &= \frac{1}{3} [2.012054 - 2.429775] = \frac{1}{3} (-0.417721) = -0.139240 \end{aligned}$$

#### Koalisi 2

$$\begin{aligned} S &= \{\text{gak}\} \\ \frac{|S|! (|N| - |S| - 1)!}{|N|!} &= \frac{1! (3 - 1 - 1)!}{3!} = \frac{1}{6} \\ \phi_2 &= \frac{1}{6} [4.159345 - 4.113923] = \frac{1}{6} (0.045422) = 0.007570 \end{aligned}$$

#### Koalisi 3

$$\begin{aligned} S &= \{\text{guna}\} \\ \frac{|S|! (|N| - |S| - 1)!}{|N|!} &= \frac{1}{6} \\ \phi_3 &= \frac{1}{6} [-1.281649 - (-0.500337)] = \frac{1}{6} (-0.781312) \\ &= -0.130219 \end{aligned}$$

#### Koalisi 4

$$\begin{aligned} S &= \{\text{gak, guna}\} \\ \frac{|S|! (|N| - |S| - 1)!}{|N|!} &= \frac{1}{3} \\ \phi_4 &= \frac{1}{3} [4.206476 - 4.202475] = \frac{1}{3} (0.004001) = 0.001334 \end{aligned}$$

# REVISI BU NINA

## Perhitungan SHAP

Tabel Nilai Logit untuk Token "aplikasi"

| No | Koalisi $S$ | $f(S)$    | $S \cup \{\text{aplikasi}\}$ | $f(S \cup \{\text{aplikasi}\})$ | Marginal Contribution |
|----|-------------|-----------|------------------------------|---------------------------------|-----------------------|
| 1  | $\emptyset$ | 2.429775  | {aplikasi}                   | 2.012054                        | -0.417721             |
| 2  | {gak}       | 4.113923  | {aplikasi,gak}               | 4.159345                        | 0.045422              |
| 3  | {guna}      | -0.500337 | {aplikasi,guna}              | -1.281649                       | -0.781312             |
| 4  | {gak,guna}  | 4.202475  | {aplikasi,gak,guna}          | 4.206476                        | 0.004001              |

### Marginal Contribution

Rumus

$$MC = f(S \cup \{i\}) - f(S)$$

$$\begin{aligned}\text{Koalisi 1} \quad MC_1 &= f(\text{aplikasi}) - f(\emptyset) \\ &= 2.012054 - 2.429775 = -0.417721\end{aligned}$$

$$\begin{aligned}\text{Koalisi 2} \quad MC_2 &= f(\text{aplikasi,gak}) - f(\text{gak}) \\ &= 4.159345 - 4.113923 = 0.045422\end{aligned}$$

$$\begin{aligned}\text{Koalisi 3} \quad MC_3 &= f(\text{aplikasi,guna}) - f(\text{guna}) \\ &= -1.281649 - (-0.500337) = -0.781312\end{aligned}$$

$$\begin{aligned}\text{Koalisi 4} \quad MC_4 &= f(\text{aplikasi,gak,guna}) - f(\text{gak,guna}) \\ &= 4.206476 - 4.202475 = 0.004001\end{aligned}$$

### Nilai SHAP

$$\phi_{\text{aplikasi}} = -0.139240 + 0.007570 - 0.130219 + 0.001334 = \boxed{-0.260555}$$

# REVISI BU NINA

## Perhitungan SHAP

**Tabel Koalisi Token “gak”**

Karena yang dihitung adalah token “gak”, maka koalisi yang digunakan adalah semua koalisi yang tidak mengandung token “gak”.

| No | Koalisi $S$                 | $S \cup \{\text{gak}\}$          | Bobot                              |
|----|-----------------------------|----------------------------------|------------------------------------|
| 1  | $\emptyset$                 | $\{\text{gak}\}$                 | $\frac{0! (2)!}{3!} = \frac{1}{3}$ |
| 2  | $\{\text{aplikasi}\}$       | $\{\text{aplikasi, gak}\}$       | $\frac{1! (1)!}{3!} = \frac{1}{6}$ |
| 3  | $\{\text{guna}\}$           | $\{\text{gak, guna}\}$           | $\frac{1! (1)!}{3!} = \frac{1}{6}$ |
| 4  | $\{\text{aplikasi, guna}\}$ | $\{\text{aplikasi, gak, guna}\}$ | $\frac{2! (0)!}{3!} = \frac{1}{3}$ |

**Koalisi 3**

$$\frac{|S|! (|N| - |S| - 1)!}{|N|!} = \frac{1! (3 - 1 - 1)!}{3!} = \frac{1}{6}$$

$$\phi_3 = \frac{1}{6} [4.202475 - (-0.500337)] = \frac{1}{6} (4.702812) = 0.783802$$

**Koalisi 4**

$$\frac{|S|! (|N| - |S| - 1)!}{|N|!} = \frac{2! (3 - 2 - 1)!}{3!} = \frac{1}{3}$$

$$\phi_4 = \frac{1}{3} [4.206476 - (-1.281649)] = \frac{1}{3} (5.488125) = 1.829375$$

**Perhitungan SHAP Token “gak”**

**Koalisi 1**

$$\frac{|S|! (|N| - |S| - 1)!}{|N|!} = \frac{0! (3 - 0 - 1)!}{3!} = \frac{1}{3}$$

$$\phi_1 = \frac{1}{3} [4.113923 - 2.429775] = \frac{1}{3} (1.684148) = 0.561383$$

**Koalisi 2**

$$\frac{|S|! (|N| - |S| - 1)!}{|N|!} = \frac{1! (3 - 1 - 1)!}{3!} = \frac{1}{6}$$

$$\phi_2 = \frac{1}{6} [4.159345 - 2.012054] = \frac{1}{6} (2.147291) = 0.357882$$



# REVISI BU NINA

## Perhitungan SHAP

### Marginal Contribution

Rumus

$$MC = f(S \cup \{i\}) - f(S)$$

Koalisi 1

$$\begin{aligned} MC_1 &= f(\text{gak}) - f(\emptyset) \\ &= 4.113923 - 2.429775 = 1.684148 \end{aligned}$$

Koalisi 2

$$\begin{aligned} MC_2 &= f(\text{aplikasi, gak}) - f(\text{aplikasi}) \\ &= 4.159345 - 2.012054 = 2.147291 \end{aligned}$$

Koalisi 3

$$\begin{aligned} MC_3 &= f(\text{gak, guna}) - f(\text{guna}) \\ &= 4.202475 - (-0.500337) = 4.702812 \end{aligned}$$

Koalisi 4

$$\begin{aligned} MC_4 &= f(\text{aplikasi, gak, guna}) - f(\text{aplikasi, guna}) \\ &= 4.206476 - (-1.281649) = 5.488125 \end{aligned}$$

### Tabel Nilai Logit untuk Token "gak"

| No | Koalisi $S$      | $f(S)$    | $S \cup \{\text{gak}\}$ | $f(S \cup \{\text{gak}\})$ | Marginal Contribution |
|----|------------------|-----------|-------------------------|----------------------------|-----------------------|
| 1  | $\emptyset$      | 2.429775  | {gak}                   | 4.113923                   | 1.684148              |
| 2  | {aplikasi}       | 2.012054  | {aplikasi, gak}         | 4.159345                   | 2.147291              |
| 3  | {guna}           | -0.500337 | {gak, guna}             | 4.202475                   | 4.702812              |
| 4  | {aplikasi, guna} | -1.281649 | {aplikasi, gak, guna}   | 4.206476                   | 5.488125              |

### Nilai SHAP

$$\begin{aligned} \phi_{\text{gak}} &= \frac{1}{3}(1.684148) + \frac{1}{6}(2.147291) + \frac{1}{6}(4.702812) + \frac{1}{3}(5.488125) \\ &= 0.561383 + 0.357882 + 0.783802 + 1.829375 \\ &= 3.532442 \end{aligned}$$

$$\phi_{\text{gak}} = 3.532442$$

# REVISI BU NINA

## Perhitungan SHAP

Tabel Koalisi Token “guna”

Karena token yang dihitung adalah “guna”, maka seluruh koalisi tidak boleh mengandung token “guna”.

| No | Koalisi S      | S U {aplikasi}        | Bobot                             |
|----|----------------|-----------------------|-----------------------------------|
| 1  | $\emptyset$    | {guna}                | $\frac{0!(2)!}{3!} = \frac{1}{3}$ |
| 2  | {aplikasi}     | {aplikasi, guna}      | $\frac{1!(1)!}{3!} = \frac{1}{6}$ |
| 3  | {gak}          | {gak, guna}           | $\frac{1!(1)!}{3!} = \frac{1}{6}$ |
| 4  | {aplikasi,gak} | {aplikasi, gak, guna} | $\frac{2!(0)!}{3!} = \frac{1}{3}$ |

Perhitungan SHAP Token “guna”

### Koalisi 1

$$S = \emptyset$$

$$\frac{|S|!(|N|-|S|-1)!}{|N|!} = \frac{0!(3-0-1)!}{3!} = \frac{1}{3}$$

$$\phi_1 = \frac{1}{3}[-0.500337 - 2.429775] = \frac{1}{3}(-2.930112) = -0.976704$$

### Koalisi 2

$$S = \{aplikasi\}$$

$$\frac{|S|!(|N|-|S|-1)!}{|N|!} = \frac{1!(3-1-1)!}{3!} = \frac{1}{6}$$

$$\phi_2 = \frac{1}{6}[-1.281649 - 2.012054] = \frac{1}{6}(-3.293703) = -0.548951$$

### Koalisi 3

$$S = \{gak\}$$

$$\frac{|S|!(|N|-|S|-1)!}{|N|!} = \frac{1}{6}$$

$$\phi_3 = \frac{1}{6}[4.202475 - 4.113923] = \frac{1}{6}(0.088552) = 0.014759$$

### Koalisi 4

$$S = \{aplikasi, gak\}$$

$$\frac{|S|!(|N|-|S|-1)!}{|N|!} = \frac{2!(3-2-1)!}{3!} = \frac{1}{3}$$

$$\phi_4 = \frac{1}{3}[4.206476 - 4.159345] = \frac{1}{3}(0.047131) = 0.015710$$

# REVISI BU NINA

## Perhitungan SHAP

### Marginal Contribution

Rumus

$$MC = f(S \cup \{i\}) - f(S)$$

Koalisi 1

$$\begin{aligned} MC_1 &= f(\text{guna}) - f(\emptyset) \\ &= -0.500337 - 2.429775 = -2.930112 \end{aligned}$$

Koalisi 2

$$\begin{aligned} MC_2 &= f(\text{aplikasi, guna}) - f(\text{aplikasi}) \\ &= -1.281649 - 2.012054 = -3.293703 \end{aligned}$$

Koalisi 3

$$\begin{aligned} MC_3 &= f(\text{gak, guna}) - f(\text{gak}) \\ &= 4.202475 - 4.113923 = 0.088552 \end{aligned}$$

Koalisi 4

$$\begin{aligned} MC_4 &= f(\text{aplikasi, gak, guna}) - f(\text{aplikasi, gak}) \\ &= 4.206476 - 4.159345 = 0.047131 \end{aligned}$$

### Tabel Nilai Logit untuk Token "guna"

| No | Koalisi $S$     | $f(S)$   | $S \cup \{\text{guna}\}$ | $f(S \cup \{\text{guna}\})$ | Marginal Contribution |
|----|-----------------|----------|--------------------------|-----------------------------|-----------------------|
| 1  | $\emptyset$     | 2.429775 | {guna}                   | -0.500337                   | -2.930112             |
| 2  | {aplikasi}      | 2.012054 | {aplikasi, guna}         | -1.281649                   | -3.293703             |
| 3  | {gak}           | 4.113923 | {gak, guna}              | 4.202475                    | 0.088552              |
| 4  | {aplikasi, gak} | 4.159345 | {aplikasi, gak, guna}    | 4.206476                    | 0.047131              |

### Nilai SHAP

$$\begin{aligned} \phi_{\text{guna}} &= \frac{1}{3}(-2.930112) + \frac{1}{6}(-3.293703) + \frac{1}{6}(0.088552) + \frac{1}{3}(0.047131) \\ &= -0.976704 + (-0.548951) + 0.014759 + 0.015710 \\ &= -1.495186 \end{aligned}$$


$$\boxed{\phi_{\text{guna}} = -1.495186}$$



# REVISI BU ANGGUN

# PERTANYAAN BU ANGGUN

"Apakah suatu kata atau token akan selalu memiliki nilai Token ID yang sama meskipun muncul di berbagai ulasan yang berbeda?"



| position | token    | token_id |
|----------|----------|----------|
| 0        | [CLS]    | 2        |
| 1        | sangat   | 310      |
| 2        | membantu | 1055     |
| 3        | dan      | 41       |
| 4        | mudah    | 783      |
| 5        | [SEP]    | 3        |


| position | token     | token_id |
|----------|-----------|----------|
| 0        | [CLS]     | 2        |
| 1        | sangat    | 310      |
| 2        | membantu  | 1055     |
| 3        | sekali    | 684      |
| 4        | dalam     | 112      |
| 5        | segala    | 1517     |
| 6        | aktivitas | 2310     |
| 7        | [SEP]     | 3        |

| position | token    | token_id |
|----------|----------|----------|
| 0        | [CLS]    | 2        |
| 1        | baik     | 342      |
| 2        | dan      | 41       |
| 3        | sangat   | 310      |
| 4        | membantu | 1055     |
| 5        | [SEP]    | 3        |


# PERTANYAAN BU ANGGUN

Apakah untuk kata/token yang sama pada ulasan yang berbeda memiliki bobot yang selalu sama pada SHAP?

mudah dan sangat membantu sekali



sangat membantu dan mudah



# PERTANYAAN BU ANGGUN

perbedaan training loss dan validation loss

## Training Loss

Training loss merupakan nilai kesalahan (error) yang dihasilkan model pada data pelatihan (training set) selama proses pembelajaran. Nilai ini untuk mengukur perbedaan antara hasil prediksi model dengan label sebenarnya. Semakin kecil nilai training loss, semakin baik kemampuan model dalam mempelajari pola yang terdapat pada data pelatihan

## Validation Loss

Validation loss merupakan nilai kesalahan model pada data validasi (validation set), yaitu data yang tidak digunakan dalam proses pembaruan bobot model. Metrik ini digunakan untuk mengevaluasi kemampuan generalisasi model terhadap data yang belum pernah dilihat selama pelatihan. Semakin menurun nilai validation loss maka kemampuannya semakin baik.



# REVISI BU ANGGUN

## Positional Encoding (PE)

Karena arsitektur Transformer tidak menggunakan mekanisme rekurensi seperti RNN maupun LSTM, model tidak memiliki informasi urutan token secara langsung. Oleh karena itu, Transformer menambahkan informasi posisi token melalui mekanisme positional encoding. Fungsi positional encoding adalah memberikan informasi mengenai posisi (urutan) setiap token dalam sebuah kalimat, sehingga model Transformer dapat memahami urutan kata.

Rumus positional encoding (dari Transformer, Vaswani et al., 2017):

Rumus

Untuk dimensi genap

$$PE(pos, 2i) = \sin\left(\frac{pos}{10000^{\frac{2i}{d_{model}}}}\right)$$

Untuk dimensi ganjil

$$PE(pos, 2i + 1) = \cos\left(\frac{pos}{10000^{\frac{2i}{d_{model}}}}\right)$$

**teks ulasan: "mudah dan sangat membantu sekali".**

Karena  $d_{model} = 4$ , maka  $i \in \{0,1\}$  (2 pasang sin-cos):

$i = 0$ : dimensi 0 (sin), dimensi 1 (cos), pembagi  $10000^{0/4} = 1$

$i = 1$ : dimensi 2 (sin), dimensi 3 (cos), pembagi  $10000^{2/4} = 100$

Catatan: Perhitungan ini menggunakan rumus sinusoidal Positional Encoding pada Transformer (Vaswani et al., 2017). Pada model IndoBERT, posisi token direpresentasikan menggunakan learnable positional embedding.

$pos$  : posisi token dalam kalimat/urutan (0,1,2,3, ...),  
 $d_{model}$  : dimensi vektor *embedding* yang dipakai model,  
 $i$  : index pasangan dimensi,  $i = 0,1,2,3, \dots$ ,  
 $2i$  : indeks dimensi genap (0, 2, 4, ...),  
 $2i + 1$  : indeks dimensi ganjil (1, 3, 5, ...),  
 $10000^{2i/d_{model}}$  : frekuensi/panjang gelombang dari fungsi sinusoidal tersebut. Semakin besar  $i$ , semakin besar pula pembagi ini, sehingga gelombangnya semakin "lambat" berubah.

# REVISI BU ANGGUN

## Positional Encoding (PE)

teks ulasan: "mudah dan sangat membantu sekali".

| Token    | Pos |
|----------|-----|
| mudah    | 0   |
| dan      | 1   |
| sangat   | 2   |
| membantu | 3   |
| sekali   | 4   |

Pos = 0 (Token: mudah)

$$PE(0, 0) = \sin\left(\frac{0}{10000^{0/4}}\right) = \sin\left(\frac{0}{1}\right) = \sin(0) = 0$$

$$PE(0, 1) = \cos\left(\frac{0}{10000^{0/4}}\right) = \cos\left(\frac{0}{1}\right) = \cos(0) = 1$$

$$PE(0, 2) = \sin\left(\frac{0}{10000^{2/4}}\right) = \sin\left(\frac{0}{100}\right) = \sin(0) = 0$$

$$PE(0, 3) = \cos\left(\frac{0}{10000^{2/4}}\right) = \cos\left(\frac{0}{100}\right) = \cos(0) = 1$$

Pos = 1 (Token: dan)

$$PE(1, 0) = \sin\left(\frac{1}{10000^{0/4}}\right) = \sin\left(\frac{1}{1}\right) = \sin(1) = 0.841471$$

$$PE(1, 1) = \cos\left(\frac{1}{10000^{0/4}}\right) = \cos\left(\frac{1}{1}\right) = \cos(1) = 0.540302$$

$$PE(1, 2) = \sin\left(\frac{1}{10000^{2/4}}\right) = \sin\left(\frac{1}{100}\right) = \sin(0.01) = 0.0099998$$

$$PE(1, 3) = \cos\left(\frac{1}{10000^{2/4}}\right) = \cos\left(\frac{1}{100}\right) = \cos(0.01) = 0.999950$$

Pos = 2 (Token: sangat)

$$PE(2, 0) = \sin\left(\frac{2}{10000^{0/4}}\right) = \sin\left(\frac{2}{1}\right) = \sin(2) = 0.909297$$

$$= \sin(2)$$

$$= 0.909297$$

$$PE(2, 1) = \cos\left(\frac{2}{10000^{0/4}}\right) = \cos\left(\frac{2}{1}\right) = \cos(2) = -0.416147$$

$$= \cos(2)$$

$$= -0.416147$$

$$PE(2, 2) = \sin\left(\frac{2}{10000^{2/4}}\right) = \sin\left(\frac{2}{100}\right) = \sin(0.02) = 0.019999$$

$$= \sin(0.02)$$

$$= 0.019999$$

$$PE(2, 3) = \cos\left(\frac{2}{10000^{2/4}}\right) = \cos\left(\frac{2}{100}\right) = \cos(0.02) = 0.999800$$

$$= \cos(0.02)$$

$$= 0.999800$$

# REVISI BU ANGGUN

## Positional Encoding (PE)

Pos = 3 (Token: membantu)

$$\begin{aligned} PE(3, 0) &= \sin\left(\frac{3}{10000^{0/4}}\right) \\ &= \sin\left(\frac{3}{1}\right) \\ &= \sin(3) \\ &= 0.141120 \end{aligned}$$

$$\begin{aligned} PE(3, 1) &= \cos\left(\frac{3}{10000^{0/4}}\right) \\ &= \cos\left(\frac{3}{1}\right) \\ &= \cos(3) \\ &= -0.989992 \end{aligned}$$

$$\begin{aligned} PE(3, 2) &= \sin\left(\frac{3}{10000^{2/4}}\right) \\ &= \sin\left(\frac{3}{100}\right) \\ &= \sin(0.03) \\ &= 0.029996 \end{aligned}$$

$$\begin{aligned} PE(3, 3) &= \cos\left(\frac{3}{10000^{2/4}}\right) \\ &= \cos\left(\frac{3}{100}\right) \\ &= \cos(0.03) \\ &= 0.999550 \end{aligned}$$

Pos = 4 (Token: sekali)

$$\begin{aligned} PE(4, 0) &= \sin\left(\frac{4}{10000^{0/4}}\right) \\ &= \sin\left(\frac{4}{1}\right) \\ &= \sin(4) \\ &= -0.756802 \end{aligned}$$

$$\begin{aligned} PE(4, 1) &= \cos\left(\frac{4}{10000^{0/4}}\right) \\ &= \cos\left(\frac{4}{1}\right) \\ &= \cos(4) \\ &= -0.653644 \end{aligned}$$

$$\begin{aligned} PE(4, 2) &= \sin\left(\frac{4}{10000^{2/4}}\right) \\ &= \sin\left(\frac{4}{100}\right) \\ &= \sin(0.04) \\ &= 0.039989 \end{aligned}$$

$$\begin{aligned} PE(4, 3) &= \cos\left(\frac{4}{10000^{2/4}}\right) \\ &= \cos\left(\frac{4}{100}\right) \\ &= \cos(0.04) \\ &= 0.999200 \end{aligned}$$

| Token    | Pos | PE(·,0)  | PE(·,1)   | PE(·,2) | PE(·,3)   |
|----------|-----|----------|-----------|---------|-----------|
| mudah    | 0   | 0        | 1.000.000 | 0       | 1.000.000 |
| dan      | 1   | 841.471  | 540.302   | 10.000  | 999.950   |
| sangat   | 2   | 909.297  | -416.147  | 19.999  | 999.800   |
| membantu | 3   | 141.120  | -989.992  | 29.996  | 999.550   |
| sekali   | 4   | -756.802 | -653.644  | 39.989  | 999.200   |

Pada implementasi sebenarnya, model IndoBERT menggunakan ukuran embedding sebesar 768 dimensi ( $d_{\text{model}} = 768$ ). Namun, pada contoh perhitungan manual digunakan  $d_{\text{model}} = 4$  sebagai ilustrasi agar proses perhitungan dapat ditampilkan secara ringkas dan mudah dipahami. Penggunaan empat dimensi hanya bertujuan untuk menunjukkan mekanisme perhitungan positional encoding, sedangkan implementasi pada model tetap menggunakan seluruh 768 dimensi sesuai arsitektur IndoBERT.



# REVISI BU ANGGUN

## Perhitungan Scaled-Dot Product Attention

$$Attention(Q, K, V) = softmax\left(\frac{Q^T K}{\sqrt{d_k}}\right) \times V \quad (2.1)$$

### Query (Q)

- Merepresentasikan informasi yang ingin dicari oleh suatu token.
- Digunakan untuk mengukur hubungan dengan setiap Key (K).

### Key (K)

- Merepresentasikan informasi yang dimiliki setiap token.
- Digunakan sebagai pembanding terhadap Query (Q).

### Value (V)

- Merepresentasikan informasi yang akan diteruskan.
- Digunakan untuk membentuk representasi baru berdasarkan bobot attention.

### Dot Product

- Menghitung tingkat kesamaan antara Query dan Key.
- Semakin besar nilainya, semakin kuat hubungan antar token.

### Scaling

- Membagi hasil Dot Product dengan  $\sqrt{d_k}$ .
- Bertujuan menjaga stabilitas nilai sebelum Softmax.

### Softmax

- Mengubah hasil scaling menjadi **bobot perhatian (attention weight)**.
- Menghasilkan nilai antara 0–1 dengan total bobot = 1.

### Attention Score

- Menunjukkan tingkat kepentingan setiap token terhadap token yang sedang diproses.
- Semakin besar nilainya, semakin besar kontribusinya.


### Weighted Sum

- Mengalikan **Attention Score** dengan **Value (V)**.
- Menghasilkan representasi baru token yang telah mempertimbangkan konteks kalimat.

### Output Self-Attention

- Representasi baru token setelah memperhatikan hubungan dengan token lain.
- Digunakan sebagai masukan ke layer Transformer berikutnya.

### Self-Attention Mechanism Flowchart





# REVISI BU ANGGUN

## Perhitungan Scaled-Dot Product Attention

### Data yang Digunakan

#### Embedding

$$X = \begin{bmatrix} 1 & 2 & 0 & 1 \\ 0 & 1 & 2 & 1 \\ 2 & 0 & 1 & 1 \end{bmatrix}$$

#### Weight Query

$$W_Q = \begin{bmatrix} 0.2 & 0.1 & 0 & 0.3 \\ 0.1 & 0.2 & 0.1 & 0 \\ 0 & 0.1 & 0.2 & 0.1 \\ 0.3 & 0 & 0.1 & 0.2 \end{bmatrix}$$

$$b_Q = [0, 0, 0, 0]$$

### Perhitungan Query Token "aplikasi"

Embedding token aplikasi

$$X_{\text{aplikasi}} = [1, 2, 0, 1]$$

Rumus

$$Q = XW_Q + b_Q$$

Dimensi 1

$$\begin{aligned} Q_1 &= (1)(0.2) + (2)(0.1) + (0)(0) + (1)(0.3) + 0 \\ &= 0.2 + 0.2 + 0 + 0.3 = 0.7 \end{aligned}$$

Dimensi 2

$$\begin{aligned} Q_2 &= (1)(0.1) + (2)(0.2) + (0)(0.1) + (1)(0) + 0 \\ &= 0.1 + 0.4 + 0 + 0 = 0.5 \end{aligned}$$

Dimensi 3

$$\begin{aligned} Q_3 &= (1)(0) + (2)(0.1) + (0)(0.2) + (1)(0.1) + 0 \\ &= 0 + 0.2 + 0 + 0.1 = 0.3 \end{aligned}$$

Dimensi 4

$$\begin{aligned} Q_4 &= (1)(0.3) + (2)(0) + (0)(0.1) + (1)(0.2) + 0 \\ &= 0.3 + 0 + 0 + 0.2 = 0.5 \end{aligned}$$

Hasil Query

$$Q = [0.7, 0.5, 0.3, 0.5]$$

### Perhitungan Key Token "aplikasi"

Weight Key

$$W_K = \begin{bmatrix} 0.1 & 0.2 & 0.1 & 0 \\ 0.2 & 0.1 & 0 & 0.2 \\ 0.1 & 0 & 0.2 & 0.1 \\ 0 & 0.2 & 0.1 & 0.2 \end{bmatrix}$$

Rumus

$$K = XW_K + b_K$$

Dimensi 1

$$\begin{aligned} K_1 &= (1)(0.1) + (2)(0.2) + (0)(0.1) + (1)(0) \\ &= 0.1 + 0.4 + 0 + 0 = 0.5 \end{aligned}$$

Dimensi 2

$$\begin{aligned} K_2 &= (1)(0.2) + (2)(0.1) + (0)(0) + (1)(0.2) \\ &= 0.2 + 0.2 + 0 + 0.2 = 0.6 \end{aligned}$$

Dimensi 3

$$\begin{aligned} K_3 &= (1)(0.1) + (2)(0) + (0)(0.2) + (1)(0.1) \\ &= 0.1 + 0 + 0 + 0.1 = 0.2 \end{aligned}$$

Dimensi 4

$$\begin{aligned} K_4 &= (1)(0) + (2)(0.2) + (0)(0.1) + (1)(0.2) \\ &= 0 + 0.4 + 0 + 0.2 = 0.6 \end{aligned}$$

Hasil Key

$$K = [0.5, 0.6, 0.2, 0.6]$$

### Perhitungan Value Token "aplikasi"

Weight Value

$$W_V = \begin{bmatrix} 0.2 & 0.1 & 0.2 & 0 \\ 0.1 & 0.2 & 0.1 & 0.2 \\ 0.2 & 0 & 0.2 & 0.1 \\ 0.1 & 0.2 & 0 & 0.2 \end{bmatrix}$$

Rumus

$$V = XW_V + b_V$$

dengan

$$b_V = [0, 0, 0, 0]$$

Dimensi 1

$$\begin{aligned} V_1 &= (1)(0.2) + (2)(0.1) + (0)(0.2) + (1)(0.1) \\ &= 0.2 + 0.2 + 0 + 0.1 = 0.5 \end{aligned}$$

Dimensi 2

$$\begin{aligned} V_2 &= (1)(0.1) + (2)(0.2) + (0)(0) + (1)(0.2) \\ &= 0.1 + 0.4 + 0 + 0.2 = 0.7 \end{aligned}$$

Dimensi 3

$$\begin{aligned} V_3 &= (1)(0.2) + (2)(0.1) + (0)(0.2) + (1)(0) \\ &= 0.2 + 0.2 + 0 + 0 = 0.4 \end{aligned}$$

Dimensi 4

$$\begin{aligned} V_4 &= (1)(0) + (2)(0.2) + (0)(0.1) + (1)(0.2) \\ &= 0 + 0.4 + 0 + 0.2 = 0.6 \end{aligned}$$

Hasil Value

$$V = [0.5, 0.7, 0.4, 0.6]$$

# REVISI BU ANGGUN

## Perhitungan Scaled-Dot Product Attention

Perhitungan Dot Product

Rumus

$$QK^T = \sum_{i=1}^4 Q_i K_i$$

Token "aplikasi" terhadap dirinya sendiri

$$QK^T = (0.7)(0.5) + (0.5)(0.6) + (0.3)(0.2) + (0.5)(0.6)$$
$$= 0.35 + 0.30 + 0.06 + 0.30 = 1.01$$

Hasil Dot Product

$$QK^T = 1.01$$

Perhitungan Softmax

Rumus

$$\alpha_i = \frac{e^{s_i}}{\sum_{j=1}^n e^{s_j}}$$

Misalkan hasil scaling terhadap ketiga token adalah

$$s = [0.505, 0.320, 0.175]$$

perhitungan weighted sum

$$Z = \sum_{i=1}^n \alpha_i V_i$$
$$Z = \alpha_1 V_1 + \alpha_2 V_2 + \alpha_3 V_3$$
$$\alpha = [0.392, 0.326, 0.282]$$
$$V = \begin{bmatrix} 0.5 & 0.7 & 0.4 & 0.6 \\ 0.3 & 0.6 & 0.5 & 0.4 \\ 0.6 & 0.2 & 0.3 & 0.7 \end{bmatrix}$$

Dimensi 1

$$Z_1 = (0.392)(0.5) + (0.326)(0.3) + (0.282)(0.6)$$
$$= 0.196 + 0.0978 + 0.1692 = 0.463$$

Dimensi 2

$$Z_2 = (0.392)(0.7) + (0.326)(0.6) + (0.282)(0.2)$$
$$= 0.2744 + 0.1956 + 0.0564 = 0.526$$

Dimensi 3

$$Z_3 = (0.392)(0.4) + (0.326)(0.5) + (0.282)(0.3)$$
$$= 0.1568 + 0.1630 + 0.0846 = 0.404$$

Dimensi 4

$$Z_4 = (0.392)(0.6) + (0.326)(0.4) + (0.282)(0.7)$$
$$= 0.2352 + 0.1304 + 0.1974 = 0.563$$

Perhitungan Scaling

Rumus

$$\text{Scaled} = \frac{QK^T}{\sqrt{d_k}}$$

dengan

$$d_k = 4$$
$$\sqrt{d_k} = \sqrt{4} = 2$$

Perhitungan

$$\text{Scaled} = \frac{1.01}{2}$$
$$= 0.505$$

Hasil Scaling

$$\text{Scaled} = 0.505$$

Menhitung eksponensial

$$e^{0.505} = 1.656$$
$$e^{0.320} = 1.377$$
$$e^{0.175} = 1.191$$

menjumlahkan hasil eksponensial

$$\sum e^s = 1.656 + 1.377 + 1.191 = 4.224$$

probabilitas attention

$$\alpha_1 = \frac{1.656}{4.224} = 0.392$$
$$\alpha_3 = \frac{1.191}{4.224} = 0.282$$

hasil softmax

$$\alpha_2 = \frac{1.377}{4.224} = 0.326$$
$$\alpha = [0.392, 0.326, 0.282]$$

Hasil attention

$$Z = [0.463, 0.526, 0.404, 0.563]$$

Output Self Attention

$$Z = [0.463, 0.526, 0.404, 0.563]$$

# REVISI BU ANGGUN

## Penulisan Contoh Perhitungan Nilai SHAP pada Draft Skripsi

**Sebelum:** menggunakan contoh ilustrasi perhitungan

**2.7.3 Contoh Perhitungan Nilai *Shapley* untuk Token “membantu”**

Sebagai ilustrasi, dilakukan perhitungan kontribusi token “*membantu*” ( $t_4$ ). Nilai *Shapley* diperoleh dari rata-rata kontribusi marginal suatu token terhadap berbagai kemungkinan kombinasi (*coalition*) token lainnya. Tabel 2.2 menunjukkan ilustrasi kontribusi marginal token “*membantu*” terhadap prediksi sentimen positif

**Tabel 2.2** Contoh Kontribusi Marginal Token “membantu”.

| Koalisi S<br>(tanpa “membantu”)                     | f(S) tanpa<br>“membantu” | f(SU{membantu}) | Kontribusi<br>Marginal |
|-----------------------------------------------------|--------------------------|-----------------|------------------------|
| ∅ (koalisi kosong)                                  | 0.33 (baseline)          | 0.51            | +0.18                  |
| {sangat}                                            | 0.44                     | 0.63            | +0.19                  |
| {sangat, mudah}                                     | 0.57                     | 0.75            | +0.18                  |
| {Aplikasi, Gojek, sangat,<br>dan, mudah, digunakan} | 0.75                     | 0.92            | +0.17                  |

Berdasarkan Tabel 2.2, token “*membantu*” secara konsisten memberikan kontribusi marginal positif sekitar +0.17 hingga +0.19 terhadap prediksi sentimen positif, terlepas dari koalisi token lainnya. Nilai *SHAPley* token tersebut dapat diaproksimasi sebagai rata-rata kontribusi marginal yang diperoleh dari berbagai koalisi.

$0.18 + 0.19 + 0.18 + 0.17$

**Sesudah:** menggunakan contoh perhitungan berdasarkan hasil model IndoBERT

Model memprediksi ulasan tersebut sebagai sentimen negatif. Pada contoh ini, perhitungan dilakukan menggunakan nilai logit aktual yang dihasilkan oleh model sebelum fungsi *softmax* diterapkan. Misalkan token yang dianalisis adalah:

$T=\{\text{aplikasi, gak, guna}\}$

Karena terdapat tiga token, maka jumlah seluruh koalisi yang mungkin terbentuk adalah  $2^3 = 8$ . Nilai logit untuk setiap koalisi ditunjukkan pada Tabel 2.2 berikut:

**Tabel 2.2** Nilai Logit seluruh Koalisi.

| Koalisi             | Logit_Negatif |
|---------------------|---------------|
| ∅                   | 2.429775      |
| {aplikasi}          | 2.012054      |
| {gak}               | 4.113923      |
| {guna}              | -0.500337     |
| {aplikasi,gak}      | 4.159345      |
| {aplikasi,guna}     | -1.281649     |
| {gak,guna}          | 4.202475      |
| {aplikasi,gak,guna} | 4.206476      |

Berdasarkan Tabel 2.2, diperoleh nilai logit kelas negatif untuk setiap kemungkinan koalisi token. Nilai logit tersebut merupakan keluaran model sebelum fungsi *softmax* diterapkan dan digunakan sebagai dasar dalam perhitungan nilai SHAP. Selanjutnya, untuk menghitung nilai SHAP suatu token, digunakan seluruh koalisi yang tidak mengandung token yang sedang dianalisis. Sebagai contoh, pada perhitungan token ‘aplikasi’, seluruh koalisi yang digunakan ditunjukkan pada Tabel 2.3.



**SEKIAN PRESENTASI INI**

**TERIMA  
KASIH**

**Oleh : Miranita Anisa Rohmah**